

UNIDAD 8: BACKPROPAGATION

CURSO

IA

```
01 import openai
02 from langchain import
03   ChatOpenAI
04
05 def generar_respuesta(prompt):
06     modelo = ChatOpenAI(
07         model = "gpt-4o"
08         temperature = 0.7
09     )
10
11     respuesta = modelo.invoke(
12         prompt
13     )
14     return respuesta.content
15
16 if __name__ == "__main__":
17     prompt = "Explicame qué
18     es la inteligencia artificial"
19     print(generar_respuesta(prompt))
```



Docente:
Gabriel Mosso



BRAINSTORM

Rep.Argentina 786, Sunchales, Sta fe.



GabrielNMosso@GMail.com



Tel: +54 351 3733383

Variables Entrenables [Weights & Biases]

El archivo ABPlayer permite adjuntar un modelo de tensorflow a cada jugador o el cual recibirá los inputs del programa y devolverá los outputs necesarios:

Este formato es **humano-legible** y **fácil de parsear**.


- ✓ Cada capa está documentada con un encabezado claro.
- ✓ Los pesos son matrices en formato fila-neurona, una fila por neurona de entrada.
- ✓ Los biases son vectores con un valor por neurona de salida.
- ✓ La secuencia de capas y dimensiones se deduce de los metadatos iniciales.

```

----- NEURAL NETWORK -----
# Inputs:      40
# Hidden Layers: 2
# Outputs:     8

#Layer Type: Dense, Neurons: 10, Activation Function: relu
#Layer Type: Dense, Neurons: 10, Activation Function: relu
#Layer Type: Dense, Neurons: 8, Activation Function: sigmoid
#Activation Threshold: 0.75
  
```

PERCEPTRON [NEURONA]



EL ARCHIVO .BOTBRAIN

ESTRUCTURA Y DISTRIBUCIÓN DE WEIGHTS & BIASES

RESUMEN DEL MODELO

ENTRADAS

40

CAPAS OCULTAS

2

NEURONAS POR CAPA

10 • 10

SALIDAS

8

RESUMEN DE DIMENSIONES

ENTRADAS
(40)

CAPA 1
(10)

CAPA 2
(10)

SALIDAS
(8)

Se almacenan en orden desde la primera capa hasta la última.

DISTRIBUCIÓN DE PARÁMETROS

PARÁMETRO	CAPA 1 (Entradas → H1)	CAPA 2 (H1 → H2)	CAPA 3 (H2 → Salidas)	TOTAL
WEIGHTS	40 x 10 = 400	10 x 10 = 100	10 x 8 = 80	580
BIASES	10	10	8	28
TOTAL VALORES	410	110	88	608

+ LENDIA DE COLORES

WEIGHTS L1 (Entradas → H1)	400 valores
BIASES L1 (10)	10 valores
WEIGHTS L2 (H1 → H2)	100 valores
BIASES L2 (10)	10 valores
WEIGHTS L3 (H2 → Salidas)	80 valores
BIASES L3 (8)	8 valores

TOTAL ALMACENADO EN .BOTBRAIN

608
VALORES

40
INPUTS

WEIGHTS HL 1 (40 × 10)

	W N1	W N2	W N3	W N4	W N5	W N6	W N7	W N8	W N9	W N10
Entrada 1	-0.002933	0.451186	-0.223138	0.000000	0.059399	0.642218	0.642181	-1.103061	0.342664	-1.092644
Entrada 2	0.000000	0.233036	0.021845	0.000000	0.000000	0.480296	0.000000	0.133304	0.444456	-0.078951
Entrada 3	0.000000	-0.451135	0.470312	0.000000	0.000000	0.000000	0.000000	0.117111	0.000000	-0.148333
Entrada 4	0.000000	1.426155	0.543065	0.000000	0.000000	0.000000	0.292929	1.387982	0.209031	0.400000
Entrada 5	0.000000	0.580979	0.300000	0.000000	0.000000	-0.000000	-0.000000	-0.000000	0.000000	0.000000
Entrada 6	0.000000	0.308463	-0.300000	0.000000	0.000000	0.317178	0.200000	-0.200000	0.200000	0.200000
Entrada 7	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Entrada 8	0.000000	0.091111	-0.300000	0.000000	0.000000	0.317059	-0.700308	0.400000	-0.400000	0.400000
Entrada 9	0.000000	0.152256	-0.690329	0.000000	0.000000	0.327174	0.223239	-0.523798	0.400000	0.000000
Entrada 10	0.000000	0.237351	0.031137	0.000000	0.000000	0.226837	0.212587	0.377064	0.178817	0.213331
Entrada 11	0.000000	0.222524	0.266329	0.000000	0.000000	0.323278	-0.227046	0.543275	-0.003132	-0.213331
Entrada 12	0.000000	0.212111	-0.456898	0.000000	0.000000	0.300000	-0.267961	-0.523798	0.243364	-0.213331
Entrada 13	0.000000	-0.155776	0.591137	0.000000	0.000000	0.683060	0.078933	0.212106	-0.039770	-0.000000
Entrada 14	0.000000	0.356436	0.471239	0.000000	0.000000	0.309065	0.000000	0.400000	0.340033	0.321806
Entrada 15	0.000000	-0.171284	0.000000	0.000000	0.000000	0.037345	0.250113	0.517983	0.057778	-0.041711
Entrada 16	0.000000	0.183217	-0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Entrada 17	0.000000	0.002291	0.270614	0.000000	0.000000	0.649984	-1.146801	0.311060	0.108137	-0.111558
Entrada 18	0.000000	0.000000	0.000000	0.000000	0.000000	0.118813	0.211908	0.374743	0.326303	0.214889
Entrada 19	0.000000	0.367461	-0.185847	0.000000	0.000000	0.517964	0.095324	0.517498	0.517930	0.331100
Entrada 20	0.000000	0.000000	0.000000	0.000000	0.000000	0.118813	0.211908	0.374743	0.326303	0.214889
Entrada 21	0.000000	0.574338	0.611330	0.000000	0.000000	0.361723	-0.122740	0.388992	0.113100	-0.513558
Entrada 22	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Entrada 23	0.000000	0.142167	0.494615	0.000000	0.000000	0.422145	-0.186436	0.233236	0.068775	0.377943
Entrada 24	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Entrada 25	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Entrada 26	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Entrada 27	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Entrada 28	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Entrada 29	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Entrada 30	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Entrada 31	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Entrada 32	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Entrada 33	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Entrada 34	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Entrada 35	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Entrada 36	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Entrada 37	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Entrada 38	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Entrada 39	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Entrada 40	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000

BIASES HL 1 (10 × 1)

BN1	-0.000000
BN2	0.000000
BN3	-0.185202
BN4	0.003002
BN5	-0.051529
BN6	-0.076902
BN7	0.272973
BN8	0.120912
BN9	0.189097
BN10	0.231482

WEIGHTS HL 2 (10 × 10)

	W N1	W N2	W N3	W N4	W N5	W N6	W N7	W N8	W N9	W N10
Desde HL 1 1	-0.000000	-0.200000	-0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	-0.000000	-0.000000
Desde HL 1 2	-0.550984	0.260818	0.063155	0.311939	0.058070	-0.093231	0.428883	0.428883	0.542454	1.241348
Desde HL 1 3	-0.950993	0.197976	0.006631	0.321664	-0.367638	0.278137	0.229093	0.260909	1.366662	0.311949
Desde HL 1 4	0.970984	0.037888	-0.779924	0.546290	0.077700	0.334800	0.818181	-0.289909	0.306677	0.448000
Desde HL 1 5	0.161128	0.222664	0.060526	0.311664	1.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Desde HL 1 6	-0.875448	0.222664	1.066635	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Desde HL 1 7	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Desde HL 1 8	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Desde HL 1 9	-0.181553	0.224251	0.310005	0.000000	0.261455	0.137466	0.787981	1.509794	-0.413999	0.513893
Desde HL 1 10	0.224251	0.222729	0.401230	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
Desde HL 1 11	0.260939	0.223939	0.001910	0.223939	0.000000	0.211151	0.689834	-0.557288	0.027386	-0.666810

BIASES HL 2 (10 × 1)

BN1	-0.066563
BN2	-0.088499
BN3	0.081771
BN4	0.327075
BN5	-0.307467
BN6	0.614761
BN7	-0.103486
BN8	-0.103580
BN9	-0.095580
BN10	0.144722

WEIGHTS OUTPUT LAYER (10 × 8)

	W N1	W N2	W N3	W N4	W N5	W N6	W N7	W N8
Desde HL 2 1	-0.301663	0.226247	-0.172652	0.256490	-0.173566	0.452496	-0.745411	-1.888465
Desde HL 2 2	0.811511	-0.456903	0.301812	1.500383	0.360939	1.448672	2.612122	-0.030200
Desde HL 2 3	-0.203155	0.611939	0.108813	-0.426352	-0.454883	-0.300837	0.379915	2.997216
Desde HL 2 4	-0.000000	-0.170336	-0.140935	0.218794	-0.140606	-0.062711	0.250272	-1.205706
Desde HL 2 5	0.129253	0.370336	0.319336	0.129136	0.369976	0.129136	0.666672	1.452978
Desde HL 2 6	-0.229195	-0.153885	-0.301517	0.517621	-1.153810	1.530463	0.666672	0.451709
Desde HL 2 7	0.137732	0.610603	0.780235	0.450819	0.450819	0.360663	0.866471	0.071206
Desde HL 2 8	0.555328	0.900531	0.223189	0.288491	2.848970	-0.641817	0.796941	-0.010868
Desde HL 2 9	0.224251	0.530979	0.980571	0.460420	0.000000	0.000000	0.000000	0.000000
Desde HL 2 10	0.360939	0.360939	0.199176	2.460480	0.360939	0.360939	0.360939	0.360939


BIASES OUTPUT LAYER (8 × 1)

BN1	-0.263993
BN2	0.564750
BN3	-2.932712
BN4	-1.434346
BN5	0.311103
BN6	-1.387880
BN7	2.365337
BN8	2.650767

El archivo ABPlayer permite adjuntar un modelo de tensorflow a cada jugador el cual recibirá los inputs del programa y devolverá los outputs necesarios:

Este formato es **humano-legible** y **fácil de parsear**.

- ✓ Cada capa está documentada con un encabezado claro.
- ✓ Los pesos son matrices en formato fila-columna, una fila por neurona de entrada.
- ✓ Los biases son vectores con un valor por neurona de salida.
- ✓ La secuencia de capas y dimensiones se deduce de los metadatos iniciales.



Inputs: 48

Hidden Layers: 2

Hidden Nodes: 48

Layer Type: Dense, ReLUmax, 50, Activation Function: sigmoid

Activation Threshold: 0.75

WEIGHTS HL 1 (40 × 10)

W N1

W N2

W N3

W N4

W N5

W N6

W N7

W N8

W N9

W N10

Inputs 1

Inputs 2

Inputs 3

Inputs 4

Inputs 5

Inputs 6

Inputs 7

Inputs 8

Inputs 9

Inputs 10

Inputs 11

Inputs 12

Inputs 13

Inputs 14

Inputs 15

Inputs 16

Inputs 17

Inputs 18

Inputs 19

Inputs 20

Inputs 21

Inputs 22

Inputs 23

Inputs 24

Inputs 25

Inputs 26

Inputs 27

Inputs 28

Inputs 29

Inputs 30

Inputs 31

Inputs 32

Inputs 33

Inputs 34

Inputs 35

Inputs 36

Inputs 37

Inputs 38

Inputs 39

Inputs 40

BIASES HL 1 (10 × 1)

W N1

W N2

W N3

W N4

W N5

W N6

W N7

W N8

W N9

W N10

Inputs 1

Inputs 2

Inputs 3

Inputs 4

Inputs 5

Inputs 6

Inputs 7

Inputs 8

Inputs 9

Inputs 10

WEIGHTS HL 2 (10 × 10)

W N1

W N2

W N3

W N4

W N5

W N6

W N7

W N8

W N9

W N10

Inputs 1

Inputs 2

Inputs 3

Inputs 4

Inputs 5

Inputs 6

Inputs 7

Inputs 8

Inputs 9

Inputs 10

BIASES HL 2 (10 × 1)

W N1

W N2

W N3

W N4

W N5

W N6

W N7

W N8

W N9

W N10

Inputs 1

Inputs 2

Inputs 3

Inputs 4

Inputs 5

Inputs 6

Inputs 7

Inputs 8

Inputs 9

Inputs 10

WEIGHTS OUTPUT LAYER (10 × 8)

W N1

W N2

W N3

W N4

W N5

W N6

W N7

W N8

W N9

W N10

Inputs 1

Inputs 2

Inputs 3

Inputs 4

Inputs 5

Inputs 6

Inputs 7

Inputs 8

Inputs 9

Inputs 10

BIASES OUTPUT LAYER (8 × 1)

W N1

W N2

W N3

W N4

W N5

W N6

W N7

W N8

Inputs 1

Inputs 2

Inputs 3

Inputs 4

Inputs 5

Inputs 6

Inputs 7

Inputs 8



BACKPROPAGATION

Backpropagation (retropropagación) es el algoritmo clave para entrenar redes neuronales. Su función principal es **calcular cómo ajustar los pesos de la red** para minimizar el error entre la salida predicha y la salida real (objetivo).

Estado inicial de la red neuronal:

• Datos de entrada (X):

El dataset contiene las muestras de entrada, cada una con sus características o variables independientes que alimentan la red.

• Etiquetas (Y):

Son los valores reales o respuestas esperadas que la red debe aprender a predecir, usadas para calcular el error durante el entrenamiento.

• Pesos y sesgos (W y b):

Al iniciar el entrenamiento, todos los pesos y sesgos de la red están inicializados con valores aleatorios (normalmente pequeños números distribuidos uniformemente o según una distribución normal).

Esto es necesario para romper la simetría y permitir que la red aprenda patrones durante la optimización.

• Propósito:

El objetivo del entrenamiento será ajustar estos pesos y sesgos aleatorios para que, al aplicar el feed forward con las entradas X, la red produzca salidas Y cada vez más cercanas a las etiquetas reales Y.



- donde f es la función de activación.

3. PREDICCIÓN

La red produce la predicción

4. BINARIZACIÓN

La predicción se transforma en binaria según un umbral

VECTOR PREDICHO (%)	
CMD_LEFT	0.12
CMD_RIGHT	0.05
CMD_ACCELERADOR	0.92
CMD_BURNER	0.83
CMD_BRAKE	0.10
CMD_FOX	0.07
CMD_CANON	0.45
CMD_BLOQUEADOR	0.66

PREDICCIÓN BINARIA (yb)



UMBRAAL (T)		0.50
13.8%		
CMD_LEFT	OFF	0
CMD_RIGHT	OFF	0
CMD_ACCELERADOR	ON	1
CMD_BURNER	ON	1
CMD_BRAKE	OFF	0
CMD_FOX	OFF	0
CMD_CANON	OFF	0
CMD_BLOQUEADOR	ON	1

Evaluación hacia adelante





CALCULO DE ERROR





3. Backpropagation (Propagación hacia atrás)

- Qué hace:
Calcula los gradientes del error respecto a cada peso y sesgo, aplicando la regla de la cadena.
- Fórmulas:
Para la capa de salida:

$$\delta^{(L)} = \nabla_{a^{(L)}} L \odot f'(z^{(L)})$$

Para cada capa previa:

$$\delta^{(l)} = \left(W^{(l+1)T} \delta^{(l+1)} \right) \odot f'(z^{(l)})$$

donde $\odot$ es multiplicación elemento a elemento y f' la derivada de la activación.


4. Actualización de Pesos y Sesgos

- Qué hace:
Ajusta los parámetros en dirección contraria al gradiente para minimizar la pérdida.
- Fórmulas de actualización (ejemplo SGD):

$$W^{(l)} \leftarrow W^{(l)} - \eta \frac{\partial L}{\partial W^{(l)}}$$

$$b^{(l)} \leftarrow b^{(l)} - \eta \frac{\partial L}{\partial b^{(l)}}$$

donde η es la tasa de aprendizaje.





EJEMPLO: CÁLCULO DE GRADIENTES EN BACKPROPAGATION


Ejemplo simple con una red neuronal: 2 entradas, 2 neuronas en la capa oculta y 1 neurona de salida (activación sigmoide)

1. ENTRADAS

$$X_1 = 0.6$$

$$X_2 = 0.9$$

2. PESOS Y BIASES (INICIALES)



3. PREDICCIÓN ($\hat{p}$)

Capa oculta:

$$n_1 = 0.6(0.10) + 0.9(-0.40) + 0.01 = 0.43$$

$$n_1 = \sigma(0.43) = 0.6050$$

$$n_2 = 0.6(-0.40) + 0.9(-0.30) - 0.02 = -0.47$$

$$n_2 = \sigma(-0.47) = 0.3845$$

Capa de salida:

$$\hat{p} = 0.6050(0.20) + 0.3845(-0.30) + 0.01 = -0.0508$$

$$\hat{p} = \sigma(-0.0508) = 0.4873$$

4. ETIQUETA REAL (y)

$$y = 1$$

5. CÁLCULO DE ERROR

Entropía Cruzada Binaria

$$L = -[y \log(\hat{p}) + (1 - y) \log(1 - \hat{p})]$$

$$L = -[1 \log(0.4873) + 0 \log(1 - 0.4873)]$$

$$L = 0.7189$$

6. BACKPROPAGATION: CÁLCULO DE GRADIENTES ($\partial L / \partial w$ y $\partial L / \partial b$)

Usando la regla de la cadena para propagar el error desde la salida hacia atrás

PASO 1: GRADIENTES EN LA CAPA DE SALIDA

1.1 Derivada de la pérdida respecto a $\hat{p}$ (salida)

$$\delta_Y = \frac{\partial L}{\partial \hat{p}} = \hat{p} - y$$

$$\delta_Y = 0.4873 - 1 = -0.5127$$

1.2 Gradientes respecto a los pesos y bias

Para cada peso entre N_j y Y :

$$\frac{\partial L}{\partial w_j} = n_j \cdot \delta_Y$$

$$\frac{\partial L}{\partial w_{Y1}} = 0.6050 \cdot (-0.5127) = -0.3102$$

$$\frac{\partial L}{\partial w_{Y2}} = 0.3845 \cdot (-0.5127) = -0.1970$$

Para el bias de salida:

$$\frac{\partial L}{\partial b} = \delta_Y = -0.5127$$

PASO 2: PROPAGAR EL ERROR A LA CAPA OCULTA

2.1 Derivada de la pérdida respecto a n_j (oculta)

$$\delta_j = \left(\sum_k w_{jk} \cdot \delta_k \right) \cdot \sigma'(n_j)$$

donde $\sigma'(z) = \sigma(z)(1 - \sigma(z))$

Para N_1 :

$$\delta_{N1} = (w_{11} \cdot \delta_Y) \cdot \sigma'(n_1)$$

$$= (0.20 \cdot (-0.5127)) \cdot (0.6050(1 - 0.6050))$$

$$= -0.1025 \cdot 0.2390 = -0.0245$$

Para N_2 :

$$\delta_{N2} = (w_{21} \cdot \delta_Y) \cdot \sigma'(n_2)$$

$$= (-0.30 \cdot (-0.5127)) \cdot (0.3845(1 - 0.3845))$$

$$= 0.1538 \cdot 0.2489 = 0.0382$$

PASO 3: GRADIENTES RESPECTO A LOS PESOS Y BIASES DE LA CAPA ENTRADA → OCULTA

$$\frac{\partial L}{\partial w_{ij}} = x_i \cdot \delta_{Nj} \quad \frac{\partial L}{\partial b_N} = \delta_N$$

$$\frac{\partial L}{\partial w_{11}} = 0.6 \cdot (-0.0245) = -0.0147$$

$$\frac{\partial L}{\partial w_{21}} = 0.9 \cdot (-0.0245) = -0.0221$$

$$\frac{\partial L}{\partial b_{N1}} = \delta_{N1} = -0.0245$$

$$\frac{\partial L}{\partial w_{12}} = 0.6 \cdot (0.0382) = 0.0229$$

$$\frac{\partial L}{\partial w_{22}} = 0.9 \cdot (0.0382) = 0.0344$$

$$\frac{\partial L}{\partial b_{N2}} = \delta_{N2} = 0.0382$$

PASO 4: RESUMEN DE GRADIENTES

Oculto → Salida (W^2, b^2)

Parámetro	Gradiente
$\partial L / \partial w_{Y1}$	-0.3102
$\partial L / \partial w_{Y2}$	-0.1970
$\partial L / \partial b$	-0.5127

Entrada → Oculta (W^1, b^1)

Parámetro	Gradiente
$\partial L / \partial w_{11}$	-0.0147
$\partial L / \partial w_{21}$	-0.0221
$\partial L / \partial b_{N1}$	-0.0245

Parámetro	Gradiente
$\partial L / \partial w_{12}$	0.0229
$\partial L / \partial w_{22}$	0.0344
$\partial L / \partial b_{N2}$	0.0382

7. ACTUALIZACIÓN DE PESOS (Regla de actualización)

$$w^{\text{nuevo}} = w^{\text{actual}} - \eta \frac{\partial L}{\partial w}, \quad b^{\text{nuevo}} = b^{\text{actual}} - \eta \frac{\partial L}{\partial b}$$

Ejemplo: con tasa de aprendizaje $\eta = 0.1$

Cada peso y sesgo se actualiza restando 0.1 veces su gradiente.

8. IDEA CLAVE

Los gradientes indican la dirección y magnitud en la que debemos cambiar cada peso y sesgo para reducir el error (L).



LEYENDA DE SÍMBOLOS

X_i : entradas
 N_j : neuronas en la capa oculta

w : pesos (conexiones)
 b : biases (sesgos)

σ : activación de una neurona (después de la sigmoide)

$\sigma(x) = \frac{1}{1 + e^{-x}}$: función sigmoide

$\sigma(x)$: término de error (derivada parcial de L)

δ : término de error (derivada parcial de L)

L : pérdida (error total)



3. Backpropagation (Propagación hacia atrás)

- Qué hace:
Calcula los gradientes del error respecto a cada peso y sesgo, aplicando la regla de la cadena.
- Fórmulas:
Para la capa de salida:

$$\delta^{(L)} = \nabla_{a^{(L)}} L \odot f'(z^{(L)})$$

Para cada capa previa:

$$\delta^{(l)} = \left(W^{(l+1)T} \delta^{(l+1)} \right) \odot f'(z^{(l)})$$

donde $\odot$ es multiplicación elemento a elemento y f' la derivada de la activación.


4. Actualización de Pesos y Sesgos

- Qué hace:
Ajusta los parámetros en dirección contraria al gradiente para minimizar la pérdida.
- Fórmulas de actualización (ejemplo SGD):

$$W^{(l)} \leftarrow W^{(l)} - \eta \frac{\partial L}{\partial W^{(l)}}$$

$$b^{(l)} \leftarrow b^{(l)} - \eta \frac{\partial L}{\partial b^{(l)}}$$

donde η es la tasa de aprendizaje.



- Pesos **positivos** → la entrada incrementa la activación de la neurona.
- Pesos **negativos** → la entrada la inhibe o reduce.
- Pesos **cercanos a cero** → la entrada casi no influye.

- Posibles causas: tasa de aprendizaje demasiado baja, regularización excesiva o datos poco informativos.

		WEIGHTS HL 1 (40 × 10)											
		W _{N1}	W _{N2}	W _{N3}	W _{N4}	W _{N5}	W _{N6}	W _{N7}	W _{N8}	W _{N9}	W _{N10}	W _{N11}	W _{N12}
40 INPUTS	EN0003	8.411138	2.31138	0.810937	0.643238	0.442328	-1.103811	0.912516	0.342644	0.263564			
	EN0004	0.000000	0.121364	0.121485	-0.000000	-0.488276	-0.000000	-0.133804	0.414243	-0.078163	0.331728		
	EN0005	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0006	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0007	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0008	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0009	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0010	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0011	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0012	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0013	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0014	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0015	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0016	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0017	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0018	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0019	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0020	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0021	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0022	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0023	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0024	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0025	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0026	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0027	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000		
	EN0028	0.000000	0.000000										

Por ejemplo, (CMD_LEFT, CMD_RIGHT, etc.), podrías ver qué combinaciones de activaciones previas hacen que se dispare cada comando.

40

INPUTS


WEIGHTS HL 1 (40 × 10)																	
		W N1	W N2	W N3	W N4	W N5	W N6	W N7	W N8	W N9	W N10	W N11	W N12	W N13	W N14	W N15	W N16
Entra 1.1	-0.00023	0.46286	0.21318	0.05029	0.84215	0.64281	-1.18014	1.00114	0.24664	0.19044	-1.02044	-0.00000	-0.00000	-0.00000	-0.00000	-0.00000	-0.00000
Entra 2.1	0.00000	0.21318	0.21318	0.00000	-0.00000	-0.00000	-0.00000	-0.00000	-0.00000	-0.00000	-0.00000	-0.00000	-0.00000	-0.00000	-0.00000	-0.00000	-0.00000
Entra 3.1	0.00000	0.41318	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 4.1	0.00000	0.14701	0.20000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 5.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 6.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 7.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 8.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 9.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 10.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 11.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 12.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 13.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 14.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 15.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 16.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 17.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 18.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 19.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 20.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 21.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 22.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 23.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 24.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 25.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 26.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 27.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 28.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 29.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 30.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 31.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 32.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 33.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 34.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 35.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 36.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 37.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 38.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 39.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entra 40.1	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00						



Análisis de Variables entrenables [W&B]:

Herramientas para analizar mejor:

- **Histogramas de pesos** → muestran distribución y dispersión.
- **Mapas de calor (heatmaps)** → para visualizar qué variables tienen más peso en cada neurona.
- **Análisis de correlación entre columnas de la matriz de pesos** → para detectar redundancia de neuronas.
- **Pruebas de “zero-out”** → poner a cero las entradas asociadas a ciertos pesos y ver el impacto en la predicción.





Pesos Efectivos Entradas -> Salidas.

Variables clave:

Las filas con colores más intensos (ya sea rojo o azul) indican entradas que tienen mayor peso en la toma de decisiones para una o varias salidas.

Influencia positiva o negativa:

- Rojo intenso:** la presencia o valor alto de esa entrada **favorece** que se active la salida.
- Azul intenso:** la presencia o valor alto de esa entrada **inhibe** que se active la salida.

Patrones repetidos:

Si una misma entrada muestra un patrón similar de color en varias columnas, es usada de manera similar por el modelo para varios comandos.

Esto podría indicar **correlación** o **redundancia**.

Especialización:



Si una entrada solo tiene un peso alto en una salida concreta, puede ser que esa variable sea un **gatillo específico** para esa acción.

Usos prácticos

Depuración y entendimiento del modelo: saber si el modelo se basa en las variables que esperamos.

Optimización de dataset: identificar entradas con poco peso para simplificar el modelo.

Análisis táctico: en este caso (avión/juego), permite ver qué parámetros son más relevantes para que el modelo decida girar, disparar, lanzar señuelos, etc.



Esto permite:

- En otras palabras, es un **análisis de sensibilidad de entradas**.

- La salida del ranking de importancia indica **qué variables de entrada son más relevantes** para las decisiones de control del sistema.

- Variables con valores altos en el ranking son aquellas cuya variación provoca cambios significativos en la activación de la primera capa, y por lo tanto impactan más en la predicción final de los comandos.

- **Priorización de sensores o datos:** Puedes identificar cuáles variables de estado realmente importan y centrar la atención en su medición y control, ignorando señales menos relevantes para reducir ruido o complejidad.
- **Optimización de estrategias:** Saber qué entradas son críticas permite diseñar tácticas más eficientes, por
- **Depuración de modelos:** Si algunas entradas esperadas como importantes aparecen con baja influencia, esto puede indicar problemas en el entrenamiento o redundancia de datos.
- **Reducción de dimensionalidad:** Las variables con poca importancia podrían eliminarse en futuros modelos, simplificando el sistema y acelerando la inferencia en tiempo real.


- El ranking permite **anticipar cómo el modelo prioriza información**
- **Interacciones clave:** algunas entradas pueden afectar múltiples neuronas simultáneamente, indicando que el modelo utiliza combinaciones de señales para tomar decisiones complejas, no solo valores individuales.

En escenarios de simulación o juego, esta información se puede usar para **mejorar la toma de decisiones autónoma**, ajustando estrategias defensivas u ofensivas según las variables más influyentes.

```

L_STALL: 1.3499
FLARE STATUS: 1.0374
ENEMY_MSL_DeltaHDG: 0.8984
CANNON_Q: 0.8959
FOX_LOCK: 0.8605
ITEM_FUEL_Dist: 0.8142
BRAKE: 0.7743
ITEM_MSLE_DeltaHDG: 0.7637
ITEM_FUEL_DeltaHDG: 0.7431
MSL_QNAIR: 0.6159
ENEMY_RADAR_TRACK: 0.5734
VISUAL_TRACK: 0.5664
ENEMY_MSL_Dist: 0.5463
ITEM_CHAFF_DeltaHDG: 0.4883
ITEM_FLARE_DeltaHDG: 0.4676
FOX_QNAIR: 0.4263
R2_ENEMY_Dist: 0.3931
MSL_LOCK: 0.3727
UP_Dist: 0.3690
LEFT_Dist: 0.3478
ITEM_MSLE_Dist: 0.3476
R1_ENEMY_Dist: 0.3175
CHAFF_STATUS: 0.3104
BURNER_REM: 0.2608
BRAKE_REM: 0.2516
FOX_Q: 0.2476
ITEM_FLARE_Dist: 0.2451
ITEM_CHAFF_Dist: 0.2410
FLARE_Q: 0.2182
RIGHT_Dist: 0.1954
DOWN_Dist: 0.1631
CHAFF_Q: 0.1517
HDG: 0.1483
HEALTH: 0.1354
FUFL: 0.1052

```





Correlación Entradas vs. Salidas

Aquí se observa **cómo cada entrada afecta directamente las salidas predichas por el modelo en la práctica, usando el DataSet real.**

Interpretación teórica del resultado

Matriz de correlación:

- Cada celda del heatmap muestra el coeficiente de correlación de Pearson entre una entrada y una salida.
- Valores cercanos a +1 indican que un aumento en la entrada tiende a generar un aumento en la salida.
- Valores cercanos a -1 indican que un aumento en la entrada tiende a generar una disminución en la salida.
- Valores cercanos a 0 indican poca o ninguna relación lineal directa entre la entrada y la salida.

Patrones observables:

- Entradas con alta correlación son **las que el modelo utiliza más directamente para tomar decisiones específicas.**
- Por ejemplo, si STALL tiene alta correlación negativa con CMD_LEFT y CMD_RIGHT, significa que el modelo tiende a reducir los movimientos laterales cuando detecta riesgo de pérdida de sustentación.
- Entradas con correlación baja pueden ser menos críticas o su influencia puede ser no lineal y combinada con otras variables.

Uso práctico de la correlación entrada-salida

Validación del modelo:

- Permite comprobar si el comportamiento del modelo es coherente con la lógica del sistema real.
- Entradas importantes deberían mostrar correlaciones significativas con las salidas esperadas.

Optimización de control y estrategia:


- Identificar qué entradas afectan más a cada comando permite **ajustar tácticas o estrategias.**
- Por ejemplo, priorizar sensores críticos para la toma de decisiones defensivas u ofensivas.

Depuración y simplificación:

- Entradas con correlación muy baja con todas las salidas podrían eliminarse para simplificar el modelo o mejorar eficiencia computacional.

Análisis táctico:

En un entorno de simulación o control autónomo, este heatmap ayuda a **visualizar cómo cada variable de estado impacta cada acción de control**, permitiendo anticipar el comportamiento del modelo frente a situaciones específicas.





Conexiones principales por Salida.

El script tiene como objetivo **visualizar gráficamente la influencia de cada entrada y de las neuronas ocultas sobre una salida específica de la red neuronal.**

- Cada conexión entre neuronas se dibuja con un grosor proporcional a la magnitud del peso, y un color que indica si la influencia es positiva o negativa.
- Se generan gráficos **uno por cada salida**, para poder analizar individualmente cómo la red decide cada acción del avión (por ejemplo CMD_FIRE o CMD_BURNER).

Usos del resultado

Interpretabilidad de la red neuronal

- Permite entender qué entradas afectan más a cada salida.
- Ayuda a detectar posibles problemas de entrenamiento, como entradas irrelevantes con pesos muy altos o conexiones que no tienen sentido físico.

Depuración de datasets

- Al ver que ciertas entradas deberían influir en una salida pero no lo hacen, se puede revisar el dataset o la lógica de recolección de datos.
- Por ejemplo, si FUEL no influye en CMD_BURNER o si STALL afecta comandos que no deberían, puede indicar inconsistencias.

Optimización de la arquitectura



- Se puede observar si algunas capas o neuronas ocultas apenas participan en la salida, lo que puede sugerir **reducción de tamaño de la red.**

Documentación y comunicación

- Facilita mostrar a otros (alumnos, colegas o supervisores) cómo la red “toma decisiones” basadas en los sensores del avión.
- Genera un material visual intuitivo para explicar el entrenamiento por refuerzo y la influencia de los inputs en las acciones del agente.

Análisis de impacto y priorización

- Identifica cuáles entradas y neuronas son críticas para el comportamiento de cada comando.
- Puede servir para diseñar estrategias de entrenamiento más eficientes, enfocando los datasets en los sensores más importantes.





```
> print("Gracias !")
> print("dudas, consultas...")
> input("Presione una tecla para salir...")
```



Docente:
Gabriel Mosso



BRAINSTORM

Rep. Argentina 786, Sunchoales, Sta fe.



GabrielNMosso@GMail.com



Tel: +54 351 3733383