

UNIDAD 10: BACKPROPAGATION

CURSO

IA

```
01 import openai
02 from langchain import
03   ChatOpenAI
04
05 def generar_respuesta(prompt):
06     modelo = ChatOpenAI(
07         model = "gpt-4o"
08         temperature = 0.7
09     )
10
11     respuesta = modelo.invoke(
12         prompt
13     )
14     return respuesta.content
15
16 if __name__ == "__main__":
17     prompt = "Explicame qué
18     es la inteligencia artificial"
19     print(generar_respuesta(prompt))
```



Docente:
Gabriel Mosso



BRAINSTORM

Rep.Argentina 786, Sunchales, Sta fe.



GabrielNMosso@GMail.com

Tel: +54 351 3733383

Variables Entrenables [Weights & Biases]

El archivo ABPlayer permite adjuntar un modelo de tensorflow a cada jugador e el cual recibirá los inputs del programa y devolverá los outputs necesarios:

Este formato es **humano-legible** y **fácil de parsear**.


- ✓ Cada capa está documentada con un encabezado claro.
- ✓ Los pesos son matrices en formato fila-neurona, una fila por neurona de entrada.
- ✓ Los biases son vectores con un valor por neurona de salida.
- ✓ La secuencia de capas y dimensiones se deduce de los metadatos iniciales.

```

----- NEURAL NETWORK -----
# Inputs:      40
# Hidden Layers: 2
# Outputs:     8

#Layer Type: Dense, Neurons: 10, Activation Function: relu
#Layer Type: Dense, Neurons: 10, Activation Function: relu
#Layer Type: Dense, Neurons: 8, Activation Function: sigmoid
#Activation Threshold: 0.75
  
```

PERCEPTRON [NEURONA]



EL ARCHIVO .BOTBRAIN

ESTRUCTURA Y DISTRIBUCIÓN DE WEIGHTS & BIASES

RESUMEN DEL MODELO

ENTRADAS
40

CAPAS OCULTAS
2

NEURONAS POR CAPA
10 · 10

SALIDAS
8

RESUMEN DE DIMENSIONES

ENTRADAS
(40)

CAPA 1
(10)

CAPA 2
(10)

SALIDAS
(8)

Se almacenan en orden desde la primera capa hasta la última.

DISTRIBUCIÓN DE PARÁMETROS

PARÁMETRO	CAPA 1 (Estradas → H1)	CAPA 2 (H1 → H2)	CAPA 3 (H2 → Salidas)	TOTAL
WEIGHTS	40 x 10 = 400	10 x 10 = 100	10 x 8 = 80	580
BIASES	10	10	8	28
TOTAL VALORES	410	110	88	608

+ LENDIA DE COLORES

- WEIGHTS L1 (Estradas → H1) 400 valores
- BIASES L1 (10) 10 valores
- WEIGHTS L2 (H1 → H2) 100 valores
- BIASES L2 (10) 10 valores
- WEIGHTS L3 (H2 → Salidas) 80 valores
- BIASES L3 (8) 8 valores

TOTAL ALMACENADO EN .BOTBRAIN

608
VALORES

40
INPUTS

WEIGHTS HL 1 (40 × 10)

	W N1	W N2	W N3	W N4	W N5	W N6	W N7	W N8	W N9	W N10
Entrada 1	-0.00293	0.45186	-0.23138	0.05929	0.64218	0.42181	-1.10361	0.34264	-1.09264	0.34264
Entrada 2	0.00000	0.23056	0.00000	0.00000	0.48266	0.48266	0.13350	0.44426	-0.08952	0.33294
Entrada 3	-0.45186	0.07032	0.00000	0.00000	0.71131	-0.45186	0.11704	0.11704	0.02623	-1.04833
Entrada 4	0.00000	1.42151	0.54305	0.00000	0.80526	0.29293	1.38782	0.20901	0.40000	0.15576
Entrada 5	0.00000	0.58079	0.00000	0.00000	-0.00717	-0.00717	-0.00717	-0.00717	-0.00717	0.00000
Entrada 6	0.00000	0.30843	-0.00000	0.00000	0.31738	0.00000	-0.00000	0.00000	0.00000	0.00000
Entrada 7	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Entrada 8	0.00000	0.09111	-0.00000	0.00000	0.31759	-0.70338	0.40000	0.40000	0.40000	0.40000
Entrada 9	0.00000	0.15256	-0.69329	0.00000	0.32734	-0.27329	0.40000	0.40000	0.40000	0.40000
Entrada 10	0.00000	0.23751	0.00000	0.00000	0.22637	0.21257	0.37704	0.17817	0.12131	0.17809
Entrada 11	0.00000	0.00000	0.00000	0.00000	0.32734	-0.27329	0.40000	0.40000	0.40000	0.40000
Entrada 12	0.00000	0.22254	0.26629	0.00000	0.52378	-0.27329	0.40000	0.40000	0.40000	0.40000
Entrada 13	0.00000	0.22254	-0.65689	0.00000	0.32734	-0.27329	0.40000	0.40000	0.40000	0.40000
Entrada 14	0.00000	-0.15576	0.00000	0.00000	0.64306	0.07893	0.21236	-0.03970	0.34583	-0.03970
Entrada 15	0.00000	0.34626	0.47129	0.00000	0.30965	0.47129	0.40000	0.40000	0.40000	0.40000
Entrada 16	0.00000	-0.17124	0.00000	0.00000	0.03745	0.25013	0.15783	0.05778	-0.04711	0.31390
Entrada 17	0.00000	0.18127	-0.00000	0.00000	0.03745	0.25013	0.15783	0.05778	-0.04711	0.31390
Entrada 18	0.00000	0.00293	0.27064	0.00000	0.44984	-1.14681	0.31160	0.10317	0.11159	-0.01276
Entrada 19	0.00000	0.00293	0.27064	0.00000	0.11813	0.21199	0.37470	0.37470	0.37470	0.37470
Entrada 20	0.00000	0.36741	-0.18987	0.00000	0.15784	0.09324	0.15784	0.15784	0.15784	0.15784
Entrada 21	0.00000	0.00000	0.00000	0.00000	0.15784	0.09324	0.15784	0.15784	0.15784	0.15784
Entrada 22	0.00000	0.57438	0.00000	0.00000	0.36123	-0.12249	0.38892	0.11390	0.11390	0.11390
Entrada 23	0.00000	0.00000	0.00000	0.00000	0.36123	-0.12249	0.38892	0.11390	0.11390	0.11390
Entrada 24	0.00000	0.14216	0.47415	0.00000	0.42245	-0.18636	0.23328	0.08775	0.37743	0.31354
Entrada 25	0.00000	0.14216	0.47415	0.00000	0.42245	-0.18636	0.23328	0.08775	0.37743	0.31354
Entrada 26	0.00000	0.00000	0.00000	0.00000	0.42245	-0.18636	0.23328	0.08775	0.37743	0.31354
Entrada 27	0.00000	0.00000	0.00000	0.00000	0.42245	-0.18636	0.23328	0.08775	0.37743	0.31354
Entrada 28	0.00000	0.00000	0.00000	0.00000	0.42245	-0.18636	0.23328	0.08775	0.37743	0.31354
Entrada 29	0.00000	0.00000	0.00000	0.00000	0.42245	-0.18636	0.23328	0.08775	0.37743	0.31354
Entrada 30	0.00000	0.00000	0.00000	0.00000	0.42245	-0.18636	0.23328	0.08775	0.37743	0.31354
Entrada 31	0.00000	0.00000	0.00000	0.00000	0.42245	-0.18636	0.23328	0.08775	0.37743	0.31354
Entrada 32	0.00000	0.00000	0.00000	0.00000	0.42245	-0.18636	0.23328	0.08775	0.37743	0.31354
Entrada 33	0.00000	0.00000	0.00000	0.00000	0.42245	-0.18636	0.23328	0.08775	0.37743	0.31354
Entrada 34	0.00000	0.00000	0.00000	0.00000	0.42245	-0.18636	0.23328	0.08775	0.37743	0.31354
Entrada 35	0.00000	0.00000	0.00000	0.00000	0.42245	-0.18636	0.23328	0.08775	0.37743	0.31354
Entrada 36	0.00000	0.00000	0.00000	0.00000	0.42245	-0.18636	0.23328	0.08775	0.37743	0.31354
Entrada 37	0.00000	0.00000	0.00000	0.00000	0.42245	-0.18636	0.23328	0.08775	0.37743	0.31354
Entrada 38	0.00000	0.00000	0.00000	0.00000	0.42245	-0.18636	0.23328	0.08775	0.37743	0.31354
Entrada 39	0.00000	0.00000	0.00000	0.00000	0.42245	-0.18636	0.23328	0.08775	0.37743	0.31354
Entrada 40	0.00000	0.00000	0.00000	0.00000	0.42245	-0.18636	0.23328	0.08775	0.37743	0.31354

BIASES HL 1 (10 × 1)

BN1	-0.00000
BN2	-0.00000
BN3	-0.18520
BN4	0.00302
BN5	-0.00129
BN6	-0.00000
BN7	-0.00000
BN8	-0.00000
BN9	0.12091
BN10	0.23182

WEIGHTS HL 2 (10 × 10)

	W N1	W N2	W N3	W N4	W N5	W N6	W N7	W N8	W N9	W N10
Desde HL 1 1	-0.00000	-0.00000	-0.00000	0.00000	-0.00000	0.00000	0.00000	0.00000	-0.00000	-0.00000
Desde HL 1 2	-0.55084	0.26018	0.00000	0.31199	0.00000	-0.00000	0.00000	0.42888	0.42888	0.42888
Desde HL 1 3	-0.55084	0.26018	0.00000	0.31199	0.00000	-0.00000	0.00000	0.42888	0.42888	0.42888
Desde HL 1 4	0.97084	0.03788	-0.77924	0.54420	0.07770	0.34800	0.31813	-0.28909	0.38667	0.44800
Desde HL 1 5	0.97084	0.03788	-0.77924	0.54420	0.07770	0.34800	0.31813	-0.28909	0.38667	0.44800
Desde HL 1 6	0.97084	0.03788	-0.77924	0.54420	0.07770	0.34800	0.31813	-0.28909	0.38667	0.44800
Desde HL 1 7	0.97084	0.03788	-0.77924	0.54420	0.07770	0.34800	0.31813	-0.28909	0.38667	0.44800
Desde HL 1 8	0.97084	0.03788	-0.77924	0.54420	0.07770	0.34800	0.31813	-0.28909	0.38667	0.44800
Desde HL 1 9	0.97084	0.03788	-0.77924	0.54420	0.07770	0.34800	0.31813	-0.28909	0.38667	0.44800
Desde HL 1 10	0.97084	0.03788	-0.77924	0.54420	0.07770	0.34800	0.31813	-0.28909	0.38667	0.44800

BIASES HL 2 (10 × 1)

BN1	-0.06653
BN2	-0.00000
BN3	0.00177
BN4	0.32705
BN5	-0.30742
BN6	0.61476
BN7	-0.10146
BN8	-0.10358
BN9	-0.09589
BN10	0.14472

WEIGHTS OUTPUT LAYER (10 × 8)

	W N1	W N2	W N3	W N4	W N5	W N6	W N7	W N8
Desde HL 2 1	-0.30163	0.22627	-0.17262	0.25490	-0.17262	0.45246	-0.74541	-1.88845
Desde HL 2 2	0.81111	-0.61003	0.31111	-0.50000	0.36000	-1.44887	2.61122	-0.00000
Desde HL 2 3	-0.20151	0.61199	0.10813	-0.42632	-0.45480	-0.30037	0.37915	2.97216
Desde HL 2 4	-0.00000	-0.17036	-0.14035	0.21874	-0.14036	-0.00000	0.20000	-1.20000
Desde HL 2 5	0.12923	0.37036	0.37036	0.37036	0.37036	0.37036	0.37036	0.37036
Desde HL 2 6	-0.22915	-0.15885	-0.30157	0.51761	-1.15810	1.59463	0.66462	0.45709
Desde HL 2 7	-0.17722	-0.61003	0.78025	0.45000	-0.45000	0.36000	0.86471	0.07100
Desde HL 2 8	0.55528	0.90051	0.22819	0.28841	0.28840	-0.64187	0.79681	-0.01000
Desde HL 2 9	0.22627	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
Desde HL 2 10	0.47421	0.53879	0.98071	0.46020	0.46020	0.06127	0.57561	1.58743

BIASES OUTPUT LAYER (8 × 1)

BN1	-0.20393
BN2	0.56475
BN3	-2.93271
BN4	-1.43436
BN5	0.31110
BN6	-1.38780
BN7	2.36537
BN8	2.65076




Variables Entrenables NEURONA 1 [Weights & Biases & Activation Function]

El archivo ABPlayer permite adjuntar un modelo de tensorflow a cada jugador el cual recibirá los inputs del programa y devolverá los outputs necesarios:

Este formato es **humano-legible** y **fácil de parsear**.

- ✓ Cada capa está documentada con un encabezado claro.
- ✓ Los pesos son matrices en formato fila-columna, una fila por neurona de entrada.
- ✓ Los biases son vectores con un valor por neurona de salida.
- ✓ La secuencia de capas y dimensiones se deduce de los metadatos iniciales.



NEURAL NETWORK	
# INPUTS:	40
# Hidden Layers:	2
# OUTPUTS:	8
Layer Type: Dense, Neurons: 10, Activation Function: ReLU	
Layer Type: Dense, Neurons: 8, Activation Function: sigmoid	
Activation Threshold: 0.0	

WEIGHTS HL 1 (40 × 10)	
	W N1 W N2 W N3 W N4 W N5 W N6 W N7 W N8 W N9 W N10
Entrada1	0.00000 0.40100 -0.20100 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada2	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada3	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada4	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada5	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada6	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada7	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada8	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada9	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada10	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada11	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada12	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada13	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada14	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada15	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada16	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada17	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada18	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada19	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada20	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada21	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada22	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada23	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada24	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada25	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada26	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada27	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada28	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada29	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada30	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada31	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada32	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada33	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada34	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada35	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada36	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada37	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada38	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada39	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Entrada40	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
BIASES HL 1 (10 × 1)	
BIAS1	-0.00000
BIAS2	-0.00000
BIAS3	-0.00000
BIAS4	-0.00000
BIAS5	-0.00000
BIAS6	-0.00000
BIAS7	-0.00000
BIAS8	-0.00000
BIAS9	-0.00000
BIAS10	-0.00000
WEIGHTS HL 2 (10 × 10)	
	W N1 W N2 W N3 W N4 W N5 W N6 W N7 W N8 W N9 W N10
Neurona HL 2.1	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Neurona HL 2.2	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Neurona HL 2.3	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Neurona HL 2.4	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Neurona HL 2.5	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Neurona HL 2.6	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Neurona HL 2.7	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Neurona HL 2.8	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Neurona HL 2.9	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Neurona HL 2.10	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
BIASES HL 2 (10 × 1)	
BIAS1	-0.00000
BIAS2	-0.00000
BIAS3	-0.00000
BIAS4	-0.00000
BIAS5	-0.00000
BIAS6	-0.00000
BIAS7	-0.00000
BIAS8	-0.00000
BIAS9	-0.00000
BIAS10	-0.00000
WEIGHTS OUTPUT LAYER (10 × 8)	
	W N1 W N2 W N3 W N4 W N5 W N6 W N7 W N8
Neurona HL 2.1	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Neurona HL 2.2	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Neurona HL 2.3	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Neurona HL 2.4	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Neurona HL 2.5	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Neurona HL 2.6	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Neurona HL 2.7	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Neurona HL 2.8	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Neurona HL 2.9	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
Neurona HL 2.10	0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000
BIASES OUTPUT LAYER (8 × 1)	
BIAS1	-0.00000
BIAS2	-0.00000
BIAS3	-0.00000
BIAS4	-0.00000
BIAS5	-0.00000
BIAS6	-0.00000
BIAS7	-0.00000
BIAS8	-0.00000



BACKPROPAGATION

Backpropagation (retropropagación) es el algoritmo clave para entrenar redes neuronales. Su función principal es **calcular cómo ajustar los pesos de la red** para minimizar el error entre la salida predicha y la salida real (objetivo).

Estado inicial de la red neuronal:

• Datos de entrada (X):

El dataset contiene las muestras de entrada, cada una con sus características o variables independientes que alimentan la red.

• Etiquetas (Y):

Son los valores reales o respuestas esperadas que la red debe aprender a predecir, usadas para calcular el error durante el entrenamiento.

• Pesos y sesgos (W y b):

Al iniciar el entrenamiento, todos los pesos y sesgos de la red están inicializados con valores aleatorios (normalmente pequeños números distribuidos uniformemente o según una distribución normal).

Esto es necesario para romper la simetría y permitir que la red aprenda patrones durante la optimización.

• Propósito:

El objetivo del entrenamiento será ajustar estos pesos y sesgos aleatorios para que, al aplicar el feed forward con las entradas X, la red produzca salidas Y cada vez más cercanas a las etiquetas reales Y.



- **Qué hace:**
Los datos de entrada pasan por todas las capas de la red, capa por capa, hasta llegar a la capa de salida.
- **Objetivo:**
Calcular la salida estimada $\hat{y}$ y el error comparándola con la salida real y .
- **Fórmula típica (capa densa):**

$$z^{(l)} = W^{(l)}a^{(l-1)} + b^{(l)}$$

$$a^{(l)} = f(z^{(l)})$$

donde f es la función de activación.



3. PREDICCIÓN

La red produce la predicción

4. BINARIZACIÓN

La predicción se transforma en binaria según un umbral



VECTOR PREDICHO (%)	
CMD_LEFT	0.12
CMD_RIGHT	0.05
CMD_ACCELERADOR	0.92
CMD_BURNER	0.83
CMD_BRAKE	0.10
CMD_FOX	0.07
CMD_CANON	0.45
CMD_BLOQUEADOR	0.66

PREDICCIÓN BINARIA (yb)

UMBRALE (°)		0.50
CMD_LEFT	OFF	0
CMD_RIGHT	OFF	0
CMD_ACCELERADOR	ON	1
CMD_BURNER	ON	1
CMD_BRAKE	OFF	0
CMD_FOX	OFF	0
CMD_CANON	OFF	0
CMD_BLOQUEADOR	ON	1



CALCULO DE ERROR





3. Backpropagation (Propagación hacia atrás)

- Qué hace:
Calcula los gradientes del error respecto a cada peso y sesgo, aplicando la regla de la cadena.
- Fórmulas:
Para la capa de salida:

$$\delta^{(L)} = \nabla_{a^{(L)}} L \odot f'(z^{(L)})$$

Para cada capa previa:

$$\delta^{(l)} = \left(W^{(l+1)T} \delta^{(l+1)} \right) \odot f'(z^{(l)})$$

donde $\odot$ es multiplicación elemento a elemento y f' la derivada de la activación.

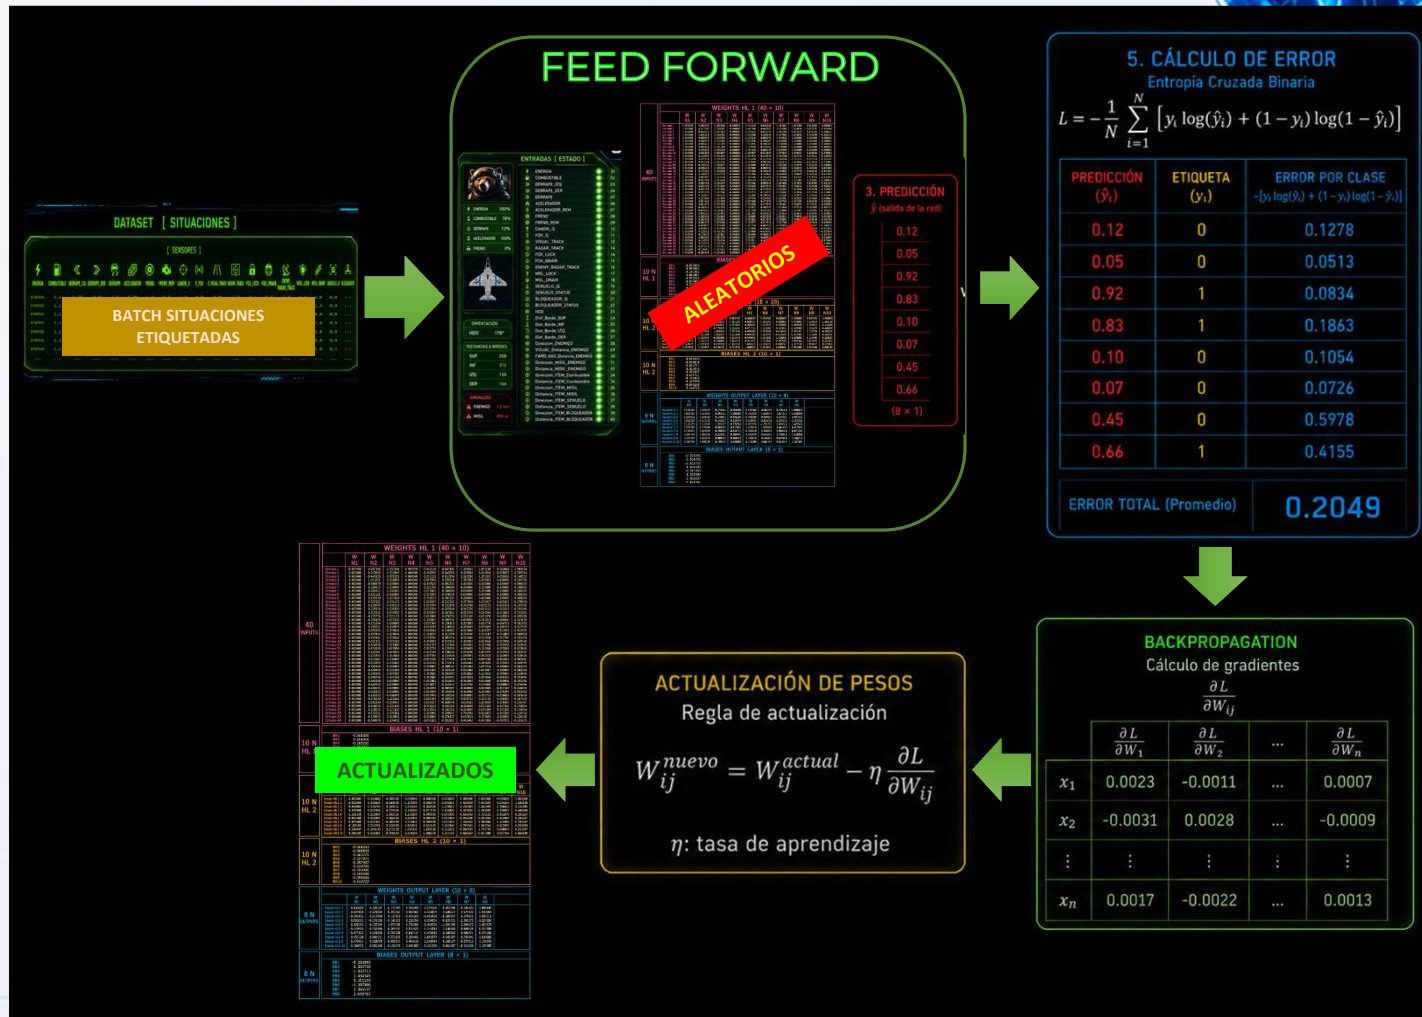
4. Actualización de Pesos y Sesgos

- Qué hace:
Ajusta los parámetros en dirección contraria al gradiente para minimizar la pérdida.
- Fórmulas de actualización (ejemplo SGD):

$$W^{(l)} \leftarrow W^{(l)} - \eta \frac{\partial L}{\partial W^{(l)}}$$

$$b^{(l)} \leftarrow b^{(l)} - \eta \frac{\partial L}{\partial b^{(l)}}$$

donde η es la tasa de aprendizaje.





EJEMPLO: CÁLCULO DE GRADIENTES EN BACKPROPAGATION


Ejemplo simple con una red neuronal: 2 entradas, 2 neuronas en la capa oculta y 1 neurona de salida (activación sigmoide)

1. ENTRADAS

$$X_1 = 0.6$$

$$X_2 = 0.9$$

2. PESOS Y BIASES (INICIALES)



3. PREDICCIÓN ($\hat{y}$)

Capa oculta:

$$n_1 = 0.6(0.10) + 0.9(0.40) + 0.01 = 0.43$$

$$n_1 = \sigma(0.43) = 0.6050$$

$$n_2 = 0.6(-0.40) + 0.9(-0.30) - 0.02 = -0.47$$

$$n_2 = \sigma(-0.47) = 0.3845$$

Capa de salida:

$$\hat{y} = 0.6050(0.20) + 0.3845(-0.30) + 0.01 = -0.0508$$

$$\hat{y} = \sigma(-0.0508) = 0.4873$$

4. ETIQUETA REAL (y)

$$y = 1$$

5. CÁLCULO DE ERROR

Entropía Cruzada Binaria

$$L = -[y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})]$$

$$L = -[1 \log(0.4873) + 0 \log(1 - 0.4873)]$$

$$L = 0.7189$$

6. BACKPROPAGATION: CÁLCULO DE GRADIENTES ($\partial L / \partial w$ y $\partial L / \partial b$)

Usando la regla de la cadena para propagar el error desde la salida hacia atrás

PASO 1: GRADIENTES EN LA CAPA DE SALIDA

1.1 Derivada de la pérdida respecto a $\hat{y}$ (salida)

$$\delta_y = \frac{\partial L}{\partial \hat{y}} = \hat{y} - y$$

$$\delta_y = 0.4873 - 1 = -0.5127$$

1.2 Gradientes respecto a los pesos y bias

Para cada peso entre N_j y Y :

$$\frac{\partial L}{\partial w_j} = n_j \cdot \delta_y$$

$$\frac{\partial L}{\partial w_{y1}} = 0.6050 \cdot (-0.5127) = -0.3102$$

$$\frac{\partial L}{\partial w_{y2}} = 0.3845 \cdot (-0.5127) = -0.1970$$

Para el bias de salida:

$$\frac{\partial L}{\partial b} = \delta_y = -0.5127$$

PASO 2: PROPAGAR EL ERROR A LA CAPA OCULTA

2.1 Derivada de la pérdida respecto a n_j (oculta)

$$\delta_j = \left(\sum_k w_{jk} \cdot \delta_k \right) \cdot \sigma'(n_j)$$

donde $\sigma'(z) = \sigma(z)(1 - \sigma(z))$

Para N_1 :

$$\delta_{N1} = (w_{11} \cdot \delta_y) \cdot \sigma'(n_1)$$

$$= (0.20 \cdot (-0.5127)) \cdot (0.6050(1 - 0.6050))$$

$$= -0.1025 \cdot 0.2390 = -0.0245$$

Para N_2 :

$$\delta_{N2} = (w_{21} \cdot \delta_y) \cdot \sigma'(n_2)$$

$$= (-0.30 \cdot (-0.5127)) \cdot (0.3845(1 - 0.3845))$$

$$= 0.1538 \cdot 0.2489 = 0.0382$$

PASO 3: GRADIENTES RESPECTO A LOS PESOS Y BIASES DE LA CAPA ENTRADA → OCULTA

$$\frac{\partial L}{\partial w_{ij}} = x_i \cdot \delta_{Nj}$$

$$\frac{\partial L}{\partial b_N} = \delta_N$$

$$\frac{\partial L}{\partial w_{11}} = 0.6 \cdot (-0.0245) = -0.0147$$

$$\frac{\partial L}{\partial w_{21}} = 0.9 \cdot (-0.0245) = -0.0221$$

$$\frac{\partial L}{\partial b_{N1}} = \delta_{N1} = -0.0245$$

$$\frac{\partial L}{\partial w_{12}} = 0.6 \cdot (0.0382) = 0.0229$$

$$\frac{\partial L}{\partial w_{22}} = 0.9 \cdot (0.0382) = 0.0344$$

$$\frac{\partial L}{\partial b_{N2}} = \delta_{N2} = 0.0382$$

PASO 4: RESUMEN DE GRADIENTES

Oculto → Salida (W^2, b^2)

Parámetro	Gradiente
$\partial L / \partial w_{y1}$	-0.3102
$\partial L / \partial w_{y2}$	-0.1970
$\partial L / \partial b$	-0.5127

Entrada → Oculta (W^1, b^1)

Parámetro	Gradiente
$\partial L / \partial w_{11}$	-0.0147
$\partial L / \partial w_{21}$	-0.0221
$\partial L / \partial b_{N1}$	-0.0245
Parámetro	Gradiente
$\partial L / \partial w_{12}$	0.0229
$\partial L / \partial w_{22}$	0.0344
$\partial L / \partial b_{N2}$	0.0382

7. ACTUALIZACIÓN DE PESOS (Regla de actualización)

$$w^{nuevo} = w^{actual} - \eta \frac{\partial L}{\partial w}, \quad b^{nuevo} = b^{actual} - \eta \frac{\partial L}{\partial b}$$

Ejemplo: con tasa de aprendizaje $\eta = 0.1$

Cada peso y sesgo se actualiza restando 0.1 veces su gradiente.

8. IDEA CLAVE

Los gradientes indican la dirección y magnitud en la que debemos cambiar cada peso y sesgo para reducir el error (L).



LEYENDA DE SÍMBOLOS

X_i : entradas
 N_j : neuronas en la capa oculta

w : pesos (conexiones)
 b : biases (sesgos)

a : activación de una neurona (después de la sigmoide)

$\sigma(x) = \frac{1}{1 + e^{-x}}$: función sigmoide

$\sigma(x)$: δ : término de error (derivada parcial de L)

L : pérdida (error total)



3. Backpropagation (Propagación hacia atrás)

- Qué hace:
Calcula los gradientes del error respecto a cada peso y sesgo, aplicando la regla de la cadena.
- Fórmulas:
Para la capa de salida:

$$\delta^{(L)} = \nabla_{a^{(L)}} L \odot f'(z^{(L)})$$

Para cada capa previa:

$$\delta^{(l)} = \left(W^{(l+1)T} \delta^{(l+1)} \right) \odot f'(z^{(l)})$$

donde $\odot$ es multiplicación elemento a elemento y f' la derivada de la activación.

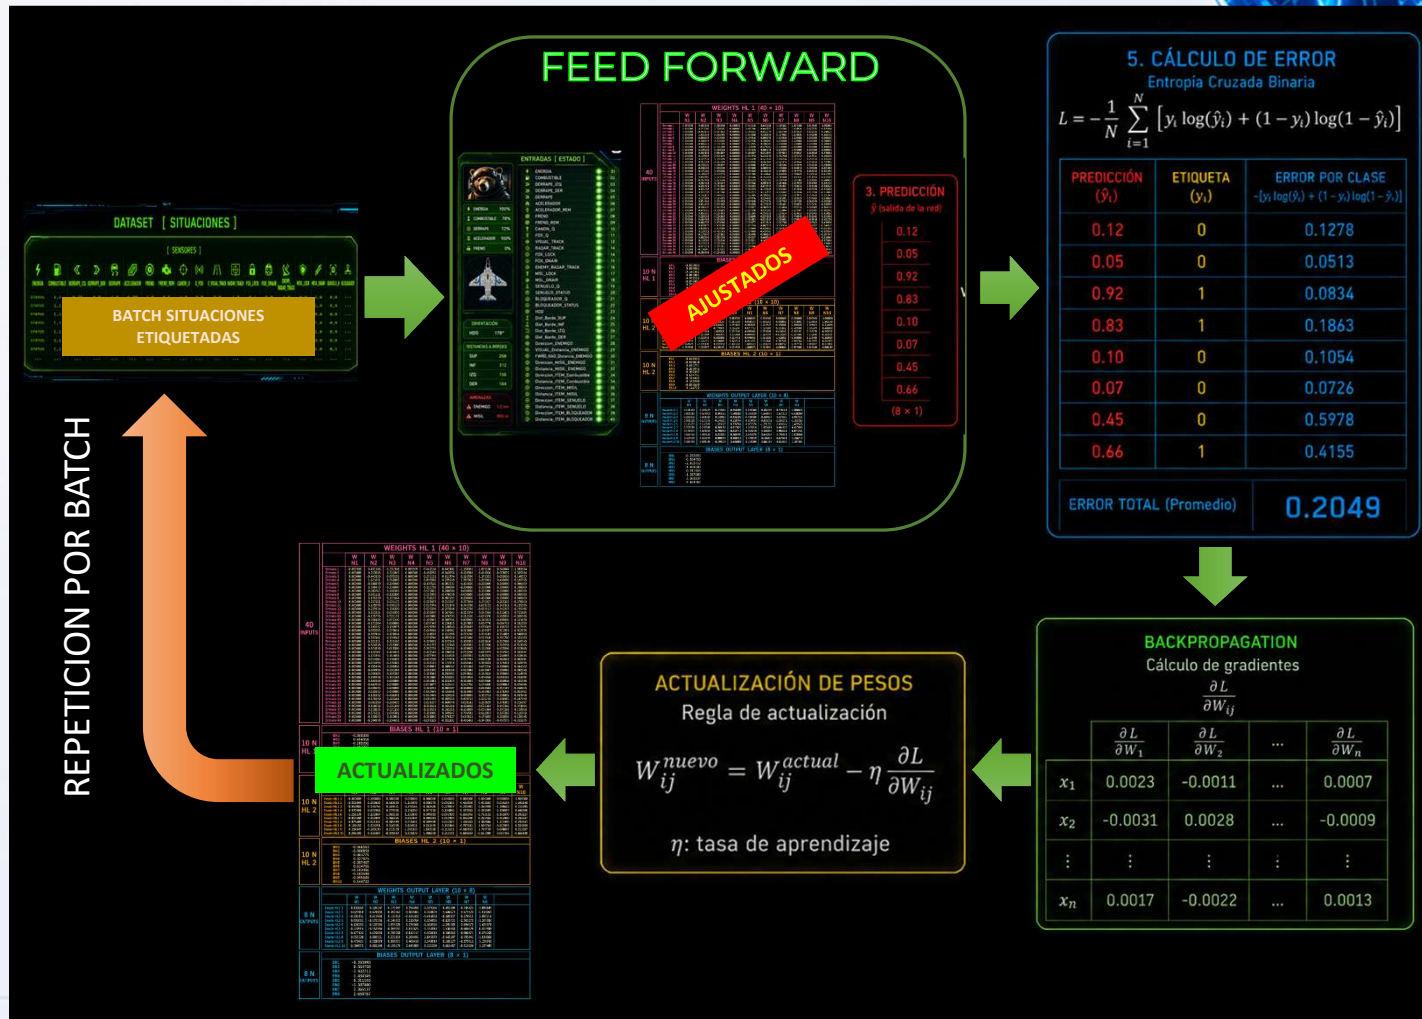
4. Actualización de Pesos y Sesgos

- Qué hace:
Ajusta los parámetros en dirección contraria al gradiente para minimizar la pérdida.
- Fórmulas de actualización (ejemplo SGD):

$$W^{(l)} \leftarrow W^{(l)} - \eta \frac{\partial L}{\partial W^{(l)}}$$

$$b^{(l)} \leftarrow b^{(l)} - \eta \frac{\partial L}{\partial b^{(l)}}$$

donde η es la tasa de aprendizaje.





Analisis de Variables entrenables [W&B]:

Observar los **pesos entrenados** de una red neuronal es como mirar el “ADN” de su aprendizaje: ahí está codificado todo lo que el modelo ha comprendido (o malcomprendido) del problema.

Definición Pesos entrenados:

En una red neuronal, cada conexión entre neuronas tiene un **peso** que indica cuánto contribuye una entrada al valor de la salida de la neurona.

- Pesos **positivos** → la entrada incrementa la activación de la neurona.
- Pesos **negativos** → la entrada la inhibe o reduce.
- Pesos **cercanos a cero** → la entrada casi no influye.

		WEIGHTS HL 1 (40 × 10)										
		W N1	W N2	W N3	W N4	W N5	W N6	W N7	W N8	W N9	W N10	
40 INPUTS	Entrada 1	-0.00203	0.12188	-0.21338	0.00029	0.04218	-0.04286	0.04218	-0.03851	0.05116	0.24264	
	Entrada 2	0.00000	0.12183	0.21245	-0.00000	-0.48276	-0.00000	-0.13384	0.41424	-0.07825	0.33778	
	Entrada 3	-0.00000	0.12183	0.21245	-0.00000	0.22112	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 4	0.00000	0.12183	0.21245	-0.00000	0.00000	0.21293	1.38782	0.20903	-0.00000	0.33778	
	Entrada 5	-0.00000	0.00000	0.00000	0.00000	-0.00000	-0.00000	-0.00000	-0.00000	0.00000	0.00000	
	Entrada 6	0.00000	0.00000	0.00000	0.00000	0.21278	0.00000	0.20000	0.20000	0.00000	0.00000	
	Entrada 7	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 8	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 9	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 10	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 11	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 12	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 13	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 14	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 15	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 16	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 17	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 18	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 19	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 20	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 21	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 22	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 23	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 24	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 25	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 26	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 27	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 28	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 29	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 30	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 31	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 32	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 33	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 34	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 35	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 36	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 37	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 38	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 39	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Entrada 40	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
10 N HL 1		BIASES HL 1 (10 × 1)										
	BN1	-0.000000										
	BN2	-0.183202										
	BN3	-0.000000										
	BN4	-0.051529										
	BN5	0.279973										
	BN6	0.000000										
	BN7	0.189907										
	BN8	0.231482										
	10 N HL 2		WEIGHTS HL 2 (10 × 10)									
		Desde HL 1.1	-0.00000	-0.20000	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	-0.00000	0.00000
Desde HL 1.2		-0.00000	0.20000	0.00000	0.00000	0.00000	-0.00000	0.48888	0.42485	0.54264	1.24348	
Desde HL 1.3		-0.00000	0.17976	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
Desde HL 1.4		0.00000	0.17976	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
Desde HL 1.5		0.00000	0.17976	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
Desde HL 1.6		0.00000	0.17976	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
Desde HL 1.7		0.00000	0.17976	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
Desde HL 1.8		0.00000	0.17976	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
Desde HL 1.9		0.00000	0.17976	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
Desde HL 1.10		0.00000	0.17976	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
10 N HL 2		BIASES HL 2 (10 × 1)										
	BN1	-0.296033										
	BN2	-0.060553										
	BN3	0.000000										
	BN4	0.327975										
	BN5	0.367467										
	BN6	0.614761										
	BN7	0.103463										
	BN8	-0.353580										
	BN9	-0.397580										
	BN10	0.144722										
8 N OUTPUTS		WEIGHTS OUTPUT LAYER (8 × 8)										
		W N1	W N2	W N3	W N4	W N5	W N6	W N7	W N8			
	Desde HL 2.1	-0.103883	0.226287	-0.172632	0.254409	-0.173038	0.452898	-0.265421	-1.086845			
	Desde HL 2.2	-0.821118	0.679093	0.391822	1.580383	0.200229	1.448872	2.471123	-0.032029			
	Desde HL 2.3	-0.201031	0.610180	0.136815	-0.424102	-0.414830	0.388817	0.379021	2.992216			
	Desde HL 2.4	0.800021	0.179036	0.144815	0.218764	0.104008	-0.628721	-2.502272	-1.265166			
	Desde HL 2.5	0.129253	0.226986	0.000000	0.000000	0.000000	0.290229	2.486672	0.429126			
	Desde HL 2.6	-0.228035	-0.102886	0.360137	0.517621	-1.153810	0.530483	-0.484629	0.417899			
	Desde HL 2.7	-0.277252	-0.000000	0.799518	0.812117	-0.000000	0.389882	0.964221	0.072340			
	Desde HL 2.8	0.001028	0.900000	0.223819	0.264491	0.264979	-0.643187	0.760641	-1.010368			
	Desde HL 2.9	0.473421	0.538979	0.989571	0.460410	1.150910	0.586127	-0.576611	1.156740			
	Desde HL 2.10	0.360973	0.861349	0.196126	0.445009	0.212390	0.861347	-0.513793	1.197485			
8 N OUTPUTS		BIASES OUTPUT LAYER (8 × 1)										
	BN1	-0.263883										
	BN2	-0.564738										
	BN3	-2.937212										
	BN4	-0.434545										
	BN5	0.311103										
	BN6	-1.387480										
	BN7	2.365137										
	BN8	2.650767										



Análisis de Variables entrenables [W&B]:

a) Importancia de las variables de entrada

- Si los pesos que conectan una característica de entrada son **altos en valor absoluto** en varias neuronas, esa característica probablemente sea **muy relevante** para la decisión final del modelo.
- Si todos los pesos de una característica están **cerca de cero**, el modelo la considera **poco o nada importante**.

Ejemplo: En un dataset de vuelo, si la variable ENEMY_MSL_Dist presenta pesos grandes en capas tempranas, probablemente sea clave para el comportamiento defensivo del avión.

b) Similitudes y redundancias

Si dos características de entrada tienen **patrones de pesos muy similares** hacia las mismas neuronas, la red las está utilizando de manera parecida. Esto puede indicar:

- Redundancia en el dataset** (variables que aportan información repetida).
- Correlación fuerte** entre variables de entrada.

c) Detección de especialización de neuronas

En capas ocultas, los pesos permiten ver cómo algunas neuronas se **especializan**:

- Una neurona con pesos fuertes están concentrados en pocas entradas podría estar detectando una **condición específica**.
- Neuronas con pesos dispersos y variados podrían estar **combinando señales** para crear características más **abstractas**.

d) Magnitud de los pesos y regularización

Pesos muy grandes:

- Pueden indicar **sobreajuste** si no se ha usado regularización adecuada (L1, L2, dropout, etc.).
- Sugieren que el modelo depende demasiado de ciertas conexiones.

Pesos muy pequeños y homogéneos:

- Pueden indicar que el modelo **no está aprendiendo lo suficiente** (underfitting).
- Posibles causas: tasa de aprendizaje demasiado baja, regularización excesiva o datos poco informativos.

		WEIGHTS HL 1 (40 × 10)									
		W N1	W N2	W N3	W N4	W N5	W N6	W N7	W N8	W N9	W N10
40 INPUTS	Entrada 1	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 2	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 3	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 4	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 5	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 6	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 7	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 8	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 9	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 10	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 11	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 12	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 13	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 14	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 15	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 16	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 17	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 18	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 19	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 20	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 21	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 22	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 23	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 24	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 25	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 26	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 27	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 28	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 29	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 30	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 31	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 32	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 33	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 34	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 35	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 36	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 37	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 38	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 39	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 40	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
10 N HL 1	BIAS1	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	BIAS2	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	BIAS3	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	BIAS4	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	BIAS5	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	BIAS6	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	BIAS7	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	BIAS8	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	BIAS9	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	BIAS10	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
10 N HL 2	WEIGHTS HL 2 (10 × 10)										
	Desde HL 1.1	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Desde HL 1.2	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Desde HL 1.3	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Desde HL 1.4	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Desde HL 1.5	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Desde HL 1.6	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Desde HL 1.7	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Desde HL 1.8	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Desde HL 1.9	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Desde HL 1.10	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
10 N HL 2	BIASES HL 2 (10 × 1)										
	BIAS1	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	BIAS2	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	BIAS3	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	BIAS4	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	BIAS5	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	BIAS6	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	BIAS7	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	BIAS8	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	BIAS9	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	BIAS10	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
8 N OUTPUTS	WEIGHTS OUTPUT LAYER (10 × 8)										
	Desde HL 2.1	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Desde HL 2.2	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Desde HL 2.3	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Desde HL 2.4	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Desde HL 2.5	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Desde HL 2.6	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	
	Desde HL 2.7	-0.00000	0.00000	0.00000	0.000						



Analisis de Variables entrenables [W&B]:

Consideraciones capa por capa:

Capa de entrada → primera capa oculta

- Aquí puedes identificar qué variables iniciales tienen mayor impacto.
- Es la mejor zona para un análisis tipo *feature importance*.

Capas intermedias

Analizar los pesos intermedios es más abstracto, porque ya no son directamente interpretables como entradas originales, sino como combinaciones aprendidas. Sin embargo, se puede estudiar si ciertas neuronas de una capa están **dominadas** por pocas conexiones fuertes o si usan muchas entradas débiles.

Capa final → salida

Aquí los pesos indican cómo cada característica “abstracta” detectada en capas previas contribuye a cada salida del modelo.

Por ejemplo, (CMD_LEFT, CMD_RIGHT, etc.), podrías ver por qué combinaciones de activaciones previas hacen que se dispare cada comando.

		WEIGHTS HL 1 (40 × 10)									
		W N1	W N2	W N3	W N4	W N5	W N6	W N7	W N8	W N9	W N10
40 INPUTS	Entrada 1	-0.00203	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 2	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 3	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 4	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 5	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 6	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 7	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 8	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 9	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 10	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 11	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 12	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 13	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 14	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 15	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 16	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 17	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 18	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 19	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 20	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 21	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 22	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 23	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 24	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 25	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 26	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 27	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 28	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 29	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 30	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 31	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 32	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 33	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 34	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 35	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 36	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 37	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 38	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 39	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Entrada 40	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
10 N HL 1	BIASES HL 1 (10 × 1)	BN1	-0.000000	BN2	0.000000	BN3	0.000000	BN4	0.000000	BN5	0.000000
		BN6	0.000000	BN7	0.000000	BN8	0.000000	BN9	0.000000	BN10	0.000000
		BN11	-0.000000	BN12	0.000000	BN13	0.000000	BN14	0.000000	BN15	0.000000
		BN16	0.000000	BN17	0.000000	BN18	0.000000	BN19	0.000000	BN20	0.000000
		BN21	-0.000000	BN22	0.000000	BN23	0.000000	BN24	0.000000	BN25	0.000000
		BN26	0.000000	BN27	0.000000	BN28	0.000000	BN29	0.000000	BN30	0.000000
		BN31	-0.000000	BN32	0.000000	BN33	0.000000	BN34	0.000000	BN35	0.000000
		BN36	0.000000	BN37	0.000000	BN38	0.000000	BN39	0.000000	BN40	0.000000
		BN41	-0.000000	BN42	0.000000	BN43	0.000000	BN44	0.000000	BN45	0.000000
		BN46	0.000000	BN47	0.000000	BN48	0.000000	BN49	0.000000	BN50	0.000000
10 N HL 2	WEIGHTS HL 2 (10 × 10)	W N1	W N2	W N3	W N4	W N5	W N6	W N7	W N8	W N9	W N10
	Desde HL 1.1	-0.00000	-0.20000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	-0.00000	0.00000
	Desde HL 1.2	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Desde HL 1.3	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Desde HL 1.4	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Desde HL 1.5	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Desde HL 1.6	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Desde HL 1.7	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Desde HL 1.8	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Desde HL 1.9	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Desde HL 1.10	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
10 N HL 2	BIASES HL 2 (10 × 1)	BN1	-0.000000	BN2	0.000000	BN3	0.000000	BN4	0.000000	BN5	0.000000
		BN6	-0.000000	BN7	0.000000	BN8	0.000000	BN9	0.000000	BN10	0.000000
		BN11	0.000000	BN12	0.000000	BN13	0.000000	BN14	0.000000	BN15	0.000000
		BN16	0.000000	BN17	0.000000	BN18	0.000000	BN19	0.000000	BN20	0.000000
		BN21	-0.000000	BN22	0.000000	BN23	0.000000	BN24	0.000000	BN25	0.000000
		BN26	0.000000	BN27	0.000000	BN28	0.000000	BN29	0.000000	BN30	0.000000
		BN31	-0.000000	BN32	0.000000	BN33	0.000000	BN34	0.000000	BN35	0.000000
		BN36	0.000000	BN37	0.000000	BN38	0.000000	BN39	0.000000	BN40	0.000000
		BN41	-0.000000	BN42	0.000000	BN43	0.000000	BN44	0.000000	BN45	0.000000
		BN46	0.000000	BN47	0.000000	BN48	0.000000	BN49	0.000000	BN50	0.000000
8 N OUTPUTS	WEIGHTS OUTPUT LAYER (10 × 8)	W N1	W N2	W N3	W N4	W N5	W N6	W N7	W N8	W N9	W N10
	Desde HL 2.1	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Desde HL 2.2	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Desde HL 2.3	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Desde HL 2.4	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Desde HL 2.5	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Desde HL 2.6	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Desde HL 2.7	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Desde HL 2.8	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Desde HL 2.9	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
	Desde HL 2.10	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000
8 N OUTPUTS	BIASES OUTPUT LAYER (8 × 1)	BN1	-0.000000	BN2	0.000000	BN3	0.000000	BN4	0.000000	BN5	0.000000
		BN6	-0.000000	BN7	0.000000	BN8	0.000000	BN9	0.000000	BN10	0.000000
		BN11	-0.000000	BN12	0.000000	BN13	0.000000	BN14	0.000000	BN15	0.000000
		BN16	-0.000000	BN17	0.000000	BN18	0.000000	BN19	0.000000	BN20	0.000000
		BN21	-0.000000	BN22	0.000000	BN23	0.000000	BN24	0.000000	BN25	0.000000
		BN26	-0.000000	BN27	0.000000	BN28	0.000000	BN29	0.000000	BN30	0.000000
		BN31	-0.000000	BN32	0.000000	BN33	0.000000	BN34	0.000000	BN35	0.000000
		BN36	-0.000000	BN37	0.000000	BN38	0.000000	BN39	0.000000	BN40	0.000000



Analisis de Variables entrenables [W&B]:

Riesgos y diagnósticos posibles al mirar pesos:

- Pesos casi idénticos entre neuronas** → la red tiene redundancia interna, lo que puede ser eficiente.
- Pesos extremadamente grandes** en pocas conexiones → sobreajuste o mal escalado de entradas.
- Patrones dispersos sin coherencia** → posible problema de datos ruidosos o hiperparámetros mal configurados.
- Pesos muy pequeños en toda la red** → aprendizaje insuficiente, tal vez por tasa de aprendizaje demasiado baja o regularización excesiva.


		WEIGHTS HL 1 (40 × 10)									
		W1	W2	W3	W4	W5	W6	W7	W8	W9	W10
40 INPUTS	Entreda 1	-0.00203	0.40506	0.23183	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 2	0.00000	0.21308	0.21308	0.00000	-0.40076	-0.40076	-0.40076	-0.40076	-0.40076	-0.40076
	Entreda 3	0.00000	0.00000	0.00000	0.00000	0.21308	0.21308	0.21308	0.21308	0.21308	0.21308
	Entreda 4	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 5	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 6	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 7	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 8	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 9	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 10	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 11	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 12	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 13	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 14	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 15	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 16	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 17	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 18	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 19	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 20	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 21	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 22	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 23	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 24	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 25	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 26	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 27	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 28	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 29	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 30	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 31	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 32	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 33	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 34	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 35	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 36	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 37	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 38	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 39	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
	Entreda 40	0.00000	0.42128	0.42128	0.00000	0.42128	0.42128	0.42128	0.42128	0.42128	0.42128
10 N HL 1		BIASES HL 1 (10 × 1)									
	BN1	-0.00000									
	BN2	-0.00000									
	BN3	-0.00000									
	BN4	-0.00000									
	BN5	-0.00000									
	BN6	-0.00000									
	BN7	-0.00000									
	BN8	-0.00000									
	BN9	-0.00000									
	BN10	-0.00000									
10 N HL 2		WEIGHTS HL 2 (10 × 10)									
	Desde HL 1.1	-0.00000	0.00000	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	-0.00000
	Desde HL 1.2	-0.00000	0.00000	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	-0.00000
	Desde HL 1.3	-0.00000	0.00000	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	-0.00000
	Desde HL 1.4	-0.00000	0.00000	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	-0.00000
	Desde HL 1.5	-0.00000	0.00000	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	-0.00000
	Desde HL 1.6	-0.00000	0.00000	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	-0.00000
	Desde HL 1.7	-0.00000	0.00000	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	-0.00000
	Desde HL 1.8	-0.00000	0.00000	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	-0.00000
	Desde HL 1.9	-0.00000	0.00000	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	-0.00000
	Desde HL 1.10	-0.00000	0.00000	-0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	0.00000	-0.00000
10 N HL 2		BIASES HL 2 (10 × 1)									
	BN1	-0.00000									
	BN2	-0.00000									
	BN3	-0.00000									
	BN4	-0.00000									
	BN5	-0.00000									
	BN6	-0.00000									
	BN7	-0.00000									
	BN8	-0.00000									
	BN9	-0.00000									
	BN10	-0.00000									
8 N OUTPUTS		WEIGHTS OUTPUT LAYER (10 × 8)									
	Desde HL 2.1	-0.103883	0.226267	-0.172632	0.254609	-0.173038	0.452398	-0.265421	-1.086645		
	Desde HL 2.2	-0.821118	0.679003	0.391022	1.508383	0.200223	1.448872	2.471123	-0.032029		
	Desde HL 2.3	-0.201031	0.410100	0.136813	-0.424102	-0.414830	0.386817	0.379023	2.902216		
	Desde HL 2.4	-0.803021	0.170106	0.144815	0.212654	0.104006	-0.626721	-2.502272	-1.265166		
	Desde HL 2.5	0.129253	0.220106	0.001028	0.376466	0.120902	0.290209	0.268672	0.429216		
	Desde HL 2.6	-0.223835	0.103386	0.368137	0.517621	-1.153810	0.530483	-0.484626	0.417899		
	Desde HL 2.7	-0.277222	0.000000	0.798128	0.821117	-0.000000	0.386817	0.000000	0.000000		
	Desde HL 2.8	0.001028	0.000000	0.223819	0.264841	0.264841	-0.643187	0.760641	-1.010386		
	Desde HL 2.9	0.473421	0.530979	0.985171	0.464810	1.150910	0.586127	-0.576611	1.150740		
	Desde HL 2.10	0.368137	0.000000	0.195126	0.445009	0.223209	0.661287	-0.513703	1.197485		
8 N OUTPUTS		BIASES OUTPUT LAYER (8 × 1)									
	BN1	-0.263883									
	BN2	-0.564738									
	BN3	-1.454545									
	BN4	0.311103									
	BN5	-1.387400									



Análisis de Variables entrenables [W&B]:

Herramientas para analizar mejor:

- **Histogramas de pesos** → muestran distribución y dispersión.
- **Mapas de calor (heatmaps)** → para visualizar qué variables tienen más peso en cada neurona.
- **Análisis de correlación entre columnas de la matriz de pesos** → para detectar redundancia de neuronas.
- **Pruebas de “zero-out”** → poner a cero las entradas asociadas a ciertos pesos y ver el impacto en la predicción.





Pesos Efectivos Entradas -> Salidas.

Variables clave:

Las filas con colores más intensos (ya sea rojo o azul) indican entradas que tienen mayor peso en la toma de decisiones para una o varias salidas.

Influencia positiva o negativa:

- Rojo intenso:** la presencia o valor alto de esa entrada **favorece** que se active la salida.
- Azul intenso:** la presencia o valor alto de esa entrada **inhibe** que se active la salida.

Patrones repetidos:

Si una misma entrada muestra un patrón similar de color en varias columnas, es usada de manera similar por el modelo para varios comandos.

Esto podría indicar **correlación** o **redundancia**.

Especialización:

Si una entrada solo tiene un peso alto en una salida concreta, puede ser que esa variable sea un **gatillo específico** para esa acción.

Usos prácticos

Depuración y entendimiento del modelo: saber si el modelo se basa en las variables que esperamos.

Optimización de dataset: identificar entradas con poco peso para simplificar el modelo.

Análisis táctico: en este caso (avión/juego), permite ver qué parámetros son más relevantes para que el modelo decida girar, disparar, lanzar señuelos, etc.


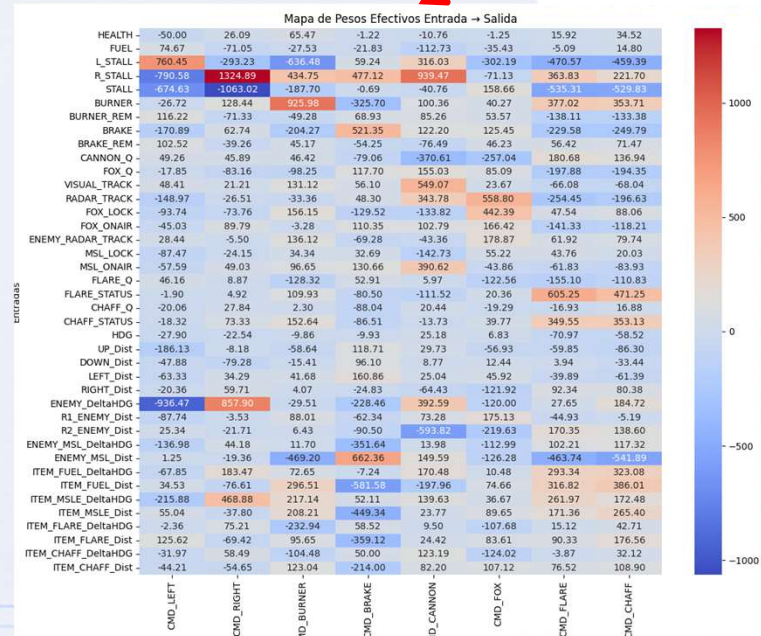


Figure 12.2 Deep network architecture with multiple layers.

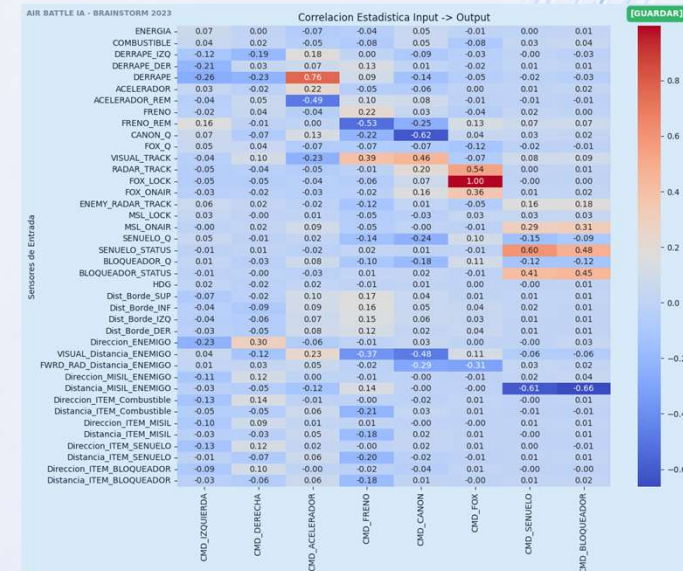



! Deep network architecture with multiple layers.





2. Correlación Entrada/Salida (`CHECK\_PyC\_02\_CORRELACION\_IO.py`)

- **Fundamento técnico:** Calcula los coeficientes de correlación (ej. Pearson) entre los valores de entrada del dataset y las salidas predichas (comandos) tras realizar la inferencia.
- **Caso de uso:** Analizar de manera empírica si el modelo realmente aprendió las lógicas esperadas entre lo que "ve" (estado) y lo que "hace" (comando) en situaciones reales.
- **Ventajas y desventajas:**
 - **Ventajas:** Muestra el comportamiento real del modelo sobre datos reales. Es fácil de leer e interpretar estadísticamente.
 - **Desventajas:** Solo captura relaciones lineales o monotónicas. Además, no implica causalidad; si dos entradas están altamente correlacionadas en el juego, puede ser difícil distinguir cuál causó la acción.



Aquí se observa **cómo cada entrada afecta directamente las salidas predichas por el modelo en la práctica, usando el DataSet real.**

Matriz de correlación:

- Cada celda del heatmap muestra el coeficiente de correlación de Pearson entre una entrada y una salida.
- Valores cercanos a +1 indican que un aumento en la entrada tiende a generar un aumento en la salida.
- Valores cercanos a -1 indican que un aumento en la entrada tiende a generar una disminución en la salida.
- Valores cercanos a 0 indican poca o ninguna relación lineal directa entre la entrada y la salida.

Patrones observables:

- Entradas con alta correlación son **las que el modelo utiliza más directamente para tomar decisiones específicas**.
- Por ejemplo, si STALL tiene alta correlación negativa con CMD_LEFT y CMD_RIGHT, significa que el modelo tiende a reducir los movimientos laterales cuando detecta riesgo de pérdida de sustentación.
- Entradas con correlación baja pueden ser menos críticas o su influencia puede ser no lineal y combinada con otras variables.

Uso práctico de la correlación entrada-salida

Validación del modelo:

- Permite comprobar si el comportamiento del modelo es coherente con la lógica del sistema real.
- Entradas importantes deberían mostrar correlaciones significativas con las salidas esperadas.

Optimización de control y estrategia:



- Identificar qué entradas afectan más a cada comando permite **ajustar tácticas o estrategias**.
- Por ejemplo, priorizar sensores críticos para la toma de decisiones defensivas u ofensivas.

Depuración y simplificación:

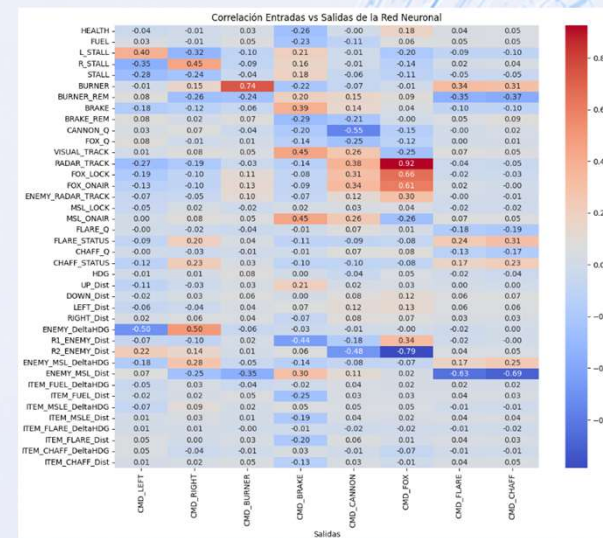
- Entradas con correlación muy baja con todas las salidas podrían eliminarse para simplificar el modelo o mejorar eficiencia computacional.

Análisis táctico:

En un entorno de simulación o control autónomo, este heatmap ayuda a **visualizar cómo cada variable de estado impacta cada acción de control**, permitiendo anticipar el comportamiento del modelo frente a situaciones específicas.



- Deep network architecture with multiple layers





Conexiones principales por Salida.

El script tiene como objetivo **visualizar gráficamente la influencia de cada entrada y de las neuronas ocultas sobre una salida específica de la red neuronal.**

- Cada conexión entre neuronas se dibuja con un grosor proporcional a la magnitud del peso, y un color que indica si la influencia es positiva o negativa.
- Se generan gráficos **uno por cada salida**, para poder analizar individualmente cómo la red decide cada acción del avión (por ejemplo CMD_FIRE o CMD_BURNER).

Usos del resultado

Interpretabilidad de la red neuronal

- Permite entender qué entradas afectan más a cada salida.
- Ayuda a detectar posibles problemas de entrenamiento, como entradas irrelevantes con pesos muy altos o conexiones que no tienen sentido físico.

Depuración de datasets

- Al ver que ciertas entradas deberían influir en una salida pero no lo hacen, se puede revisar el dataset o la lógica de recolección de datos.
- Por ejemplo, si FUEL no influye en CMD_BURNER o si STALL afecta comandos que no deberían, puede indicar inconsistencias.

Optimización de la arquitectura



- Se puede observar si algunas capas o neuronas ocultas apenas participan en la salida, lo que puede sugerir **reducción de tamaño de la red.**


Documentación y comunicación

- Facilita mostrar a otros (alumnos, colegas o supervisores) cómo la red “toma decisiones” basadas en los sensores del avión.
- Genera un material visual intuitivo para explicar el entrenamiento por refuerzo y la influencia de los inputs en las acciones del agente.

Análisis de impacto y priorización

- Identifica cuáles entradas y neuronas son críticas para el comportamiento de cada comando.
- Puede servir para diseñar estrategias de entrenamiento más eficientes, enfocando los datasets en los sensores más importantes.








7. Dependencia Parcial

(`CHECK\_SyA\_03\_DEPENDENCIA\_PARCIAL.py`)

- **Fundamento técnico:** Gráfico de Dependencia Parcial (PDP) que muestra el efecto marginal de una variable específica sobre la predicción, promediando el efecto de todas las demás características.
- **Caso de uso:** Comprobar si la relación entre un sensor (ej. altitud) y un comando (ej. descender) es lineal o si tiene un umbral claro de activación (comportamiento escalonado).
- **Ventajas y desventajas:**
 - *Ventajas:* Muy fácil de interpretar. Resulta ideal para ver efectos globales no lineales y puntos de inflexión.
 - *Desventajas:* Asume que las variables son independientes. Si hay entradas muy correlacionadas (ej. velocidad y empuje), los promedios pueden calcularse sobre estados "físicamente imposibles", distorsionando el resultado.






6. Sensibilidad de Comandos

(`CHECK\_SyA\_02\_SENSIBILIDAD\_CMD.py`)

- **Fundamento técnico:** Mide el gradiente (derivada local) de una salida en función de una entrada, evaluado sobre los datos. Muestra cuánto cambiaría la salida ante una micro-perturbación de la entrada.
- **Caso de uso:** Detectar cuán vulnerable o robusto es el modelo a ruido en ciertos sensores, y entender qué variables son críticas en escenarios límite.
- **Ventajas y desventajas:**
 - *Ventajas:* Revela vulnerabilidades locales exactas y la susceptibilidad del modelo a ataques adversarios o ruido.
 - *Desventajas:* Es una métrica estrictamente local y puntual. Un alto gradiente no significa que la variable sea globalmente importante, sino que es sensible en ese instante.

AIR BATTLE 1A - BRAINSTORM 2023






6. Sensibilidad de Comandos

(`CHECK\_SyA\_02\_SENSIBILIDAD\_CMD.py`)

- **Fundamento técnico:** Mide el gradiente (derivada local) de una salida en función de una entrada, evaluado sobre los datos. Muestra cuánto cambiaría la salida ante una micro-perturbación de la entrada.
- **Caso de uso:** Detectar cuán vulnerable o robusto es el modelo a ruido en ciertos sensores, y entender qué variables son críticas en escenarios límite.
- **Ventajas y desventajas:**
 - *Ventajas:* Revela vulnerabilidades locales exactas y la susceptibilidad del modelo a ataques adversarios o ruido.
 - *Desventajas:* Es una métrica estrictamente local y puntual. Un alto gradiente no significa que la variable sea globalmente importante, sino que es sensible en ese instante.







5. Gradientes Integrados




(`CHECK\_SyA\_01\_GRADIENTES\_INTEGRADOS.py`)

- **Fundamento técnico:** Método axiomático de atribución. Integra los gradientes de la salida respecto a la entrada a lo largo de un camino interpolado desde un estado neutral (baseline) hasta el estado actual.
- **Caso de uso:** Explicar decisiones individuales del modelo con precisión milimétrica (ej. "¿Por qué el avión disparó exactamente en este frame de la partida?").

- Ventajas y desventajas:

- **Ventajas:** Muy sólido matemáticamente (cumple con axiomas de sensibilidad). Gran precisión para atribuir causalidad en modelos altamente no lineales.
- **Desventajas:** Ejecución lenta y pesada. Exige elegir un buen "baseline" (estado neutro), lo cual a veces no es evidente (ej. ¿qué significa "ausencia de sensores"?).







```
01 import openai
02 from IPython import
03     ChatOpenAI
04
05 def generar_respuesta(prompt):
06     modelo = ChatOpenAI(
07         model = "gpt-4o"
08         temperature = 0.7
09     )
10     respuesta = modelo.invoke(
11     ) prompt
12     return respuesta.content
13 )
14
15 if __name__ == "__main__":
16     print("¡Gracias!")
17     print("dudas, consultas...")
18     input("Presione una tecla para salir...")
```

> print("Gracias !")

> print("dudas, consultas...")

> input("Presione una tecla para salir...")



Docente:
Gabriel Mosso



BRAINSTORM

Rep. Argentina 786, Sunchoales, Sta fe.



GabrielNMosso@GMail.com



Tel: +54 351 3733383

